Modelos de desarrollo de Software

y su adaptación a proyectos con Inteligencia Artificial

¿Por qué importan los modelos?

"Antes de poner el primer ladrillo, necesitas un **PLAN**"

Imagina construir una casa sin planos: ¿Dónde van las tuberías? ¿ Y las ventanas?

Definición visual
Un modelo de desarrollo es un plan maestro del software. Define etapas, el orden y los entregables.

Concepto Clave
Un modelo no te dice QUÉ hacer técnicamente (código), sino COMO organizarte para hacerlo eficientemente.

"El éxito de un proyecto de IA depende más

¿Qué pasaría si trabajaras sin ningún plan?

Mapa General: Los 9 Modelos

Clásicos

- Modelo en cascada
- Modelo en V

Enfoque: Estructura y Control

Iterativos/Ágiles

- Iterativo e incremental
- Modelo en espiral
- Scrum
- Kanban
- Extreme Programming (XP)

Enfoque: Flexibilidad y Feedback

Especializados en IA

- CRISP-DM
- MLOps

Enfoque: Datos y ciclo de vida ML

1970s	1980s	1990s	2000s	Hoy
Cascada (Winston Royce)	Modelo en Espiral Modelo en V	Scrum, XP Manifiesto Ágil	Kanban (Software) CRISP-DM	MLOps DevOps + Data

Modelo en cascada (Waterfall)

1.Requisitos

2. Diseño

3. Implementación

4. Pruebas

5. Integración

6. Mantenimiento

Ventajas

- Estructura clara y secuencial
- Documentación exhaustiva
- Fácil de gestionar

Desventajas

- Inflexible ante cambios
- Errores se detectan tarde
- Cliente ve el producto al FINAL

Evaluación para IA: POCO ADECUADO

La IA tiene alta incertidumbre. En cascada, si el modelo no funciona en la etapa de pruebas (paso 4), volver a requisitos (paso 1) es extremadamente costoso.

Analogía: Hornear un pastel

Sigues la receta paso a paso. No puedes probar si quedó dulce o salado hasta que ya salió del horno y esta decorado. ¡Demasiado tarde para arreglarlo!

Modelo en V (Verificación y validación)

Ventaja principal

Calidad planteada desde el inicio.
Cada fase de desarrollo tiene una fase de prueba espejo asociada antes de empezar a programar.

Adaptación a IA

Útil para definir COMO va a evaluar tu modelo antes de construirlo. Evita el "entrenar a ciegas"

Crucial en sistemas críticos(Medicina, Coches autónomos.)

Ejemplo práctico

Definir en la fase de requisitos:
"El modelo de clasificación debe tener una métrica Recall >95% en el data set de validación"

Iterativo vs Incremental

Iterativo

“Mejora lo que ya existe”

Como un escultor o escritor: empiezas con un borrador y lo pules capa por capa hasta

Incremental

“Añadir piezas nuevas”

Como construir un edificio piso a piso. El primer piso es usable antes de que exista el

Para Inteligencia Artificial

El desarrollo de IA es altamente iterativo por naturaleza. Rara vez obtienes el modelo perfecto a la primera; necesitas experimentar, medir y ajustar repetidamente.

Modelo en Espiral

5 riesgos típicos en IA

- Riesgos de datos (Calidad / cantidad)
- Riesgos de Modelo (Performance)
- Riesgo Ético (Sesgo / Discriminación)
- Riesgo de integración
- Riesgo regulatorio (GDPR/Compliance)

Recomendación para IA

ALTAMENTE RECOMENDADO

Ideal para proyectos grandes, complejos y con alta incertidumbre donde fallar es costoso.

Ejemplo práctico

Detección de fraude bancario: se requiere validar cumplimiento legal y riesgos financieros en cada ciclo antes de avanzar.

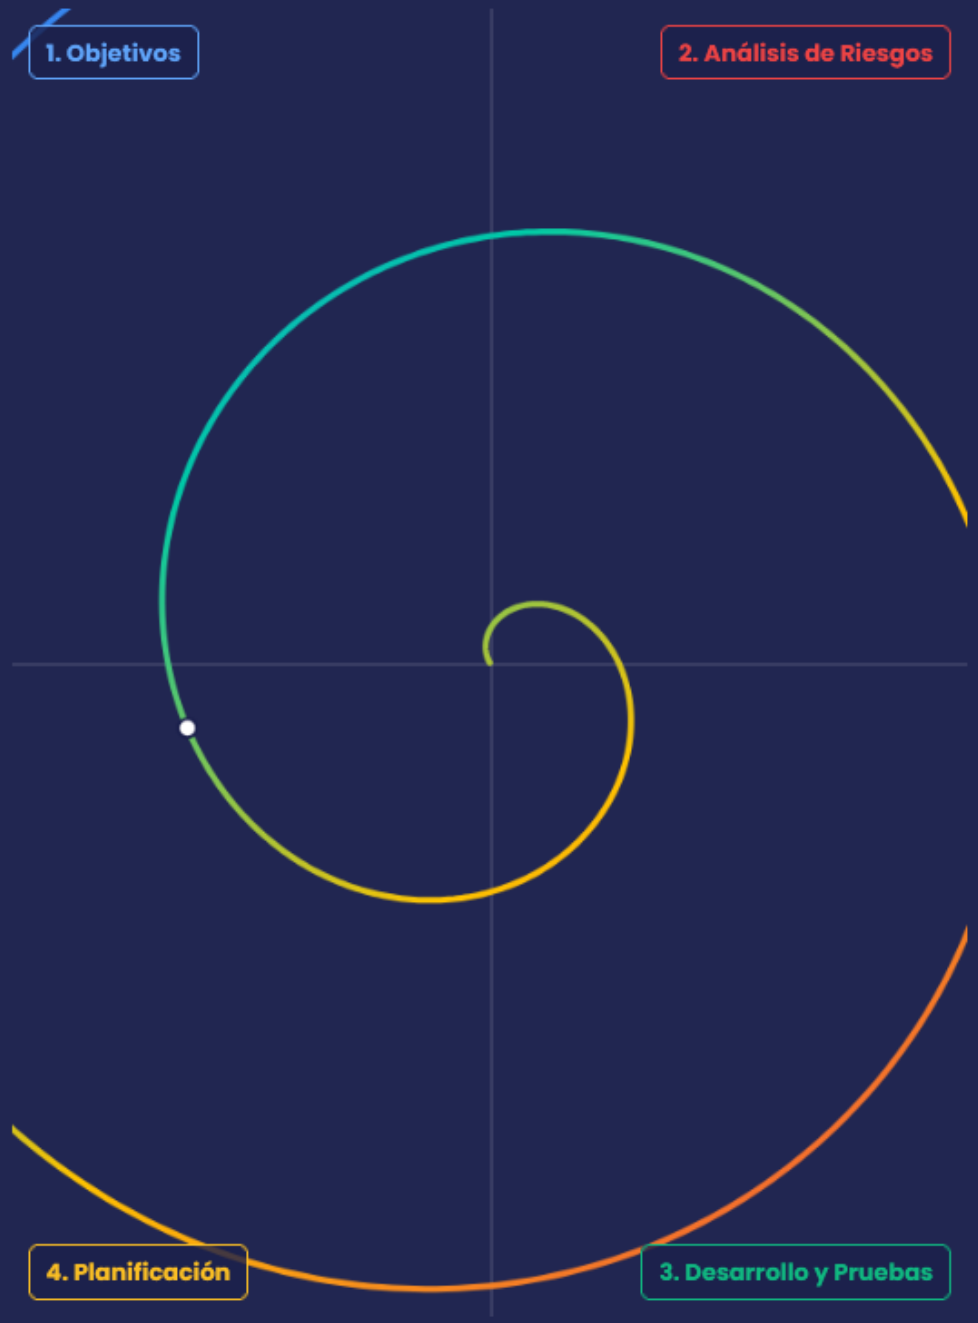

Scrum (Framework Ágil)

Roles en Scrum

Product Owner
Define QUÉ se hace (Prioridades)

Scrum Master
Facilitador, elimina obstáculos

Dev Team
Multidisciplinar (DS + ML + Devs)

Historia de Usuario

STORY-42

Como analista de seguridad,
Quiero que el sistema detecte emails de phishing,
Para reducir el riesgo de fraude.

Criterios de Aceptación (DoD):

- Accuracy > 95% en dataset de test.
- Latencia de inferencia < 200ms.
- Modelo versionado en MLflow.

Adaptación IA: "SPIKES"
ALTAMENTE RECOMENDADO
En IA, a veces no sabes si algo es posible. Usas un **Spike** (Spring de investigación) acotado en tiempo para probar una hipótesis antes de comprometerte a construirlo.

El Gran Reto: Estimación
Es muy difícil estimar tareas ML. "¿Entrenar este modelo tomara 2 horas o 2 semanas?"
Requiere flexibilidad en el Spring Backlog.

Backlog ∞	Experimentando WIP: 2	Entrenando WIP: 1	Validando WIP: 2	Producción ∞	Monitoreando ∞
Recolectar dataset de fraude v2 Data JP	Testear features de geo-localización Feat. Eng AL	Entrenamiento XGBoost v3 (Hyperopt) Train Bot	Revisión de métricas (F1-Score) Eval Team	Modelo Fraude v1.2 (Deployed) Prod Ops	Alerta de Data Drift: Income Alert Bot
Investigar Transformer vs LSTM R&D AL	Limpieza de outliers Data JP				
Configurar GPU cluster Infra MK					

Concepto WIP (Work In Progress)
Limitar el trabajo en curso (ej. "Max 2 experimentos a la vez") evita cuellos de botella y mejora el flujo. **"Deja de empezar y empieza a terminar".**

Ideal para MLOps
Perfecto para equipos de **Mantenimiento y Operaciones** que reciben peticiones continuas (bugs, reentrenamientos, nuevas features) sin sprints fijos.

Ejemplo Real
Un equipo de Data Science gestionando múltiples experimentos en paralelo. Si un modelo falla en validación, vuelve atrás sin romper un sprint completo.

Kanban para IA y MLOps

Extreme Programming (XP)

TDD
Test-Driven Development

Pair Programming
Dos personas, un equipo

Integración Contínua
Merge de código diario

Releases Pequeños
Entregas frecuentes

Refactoring
Mejora continua del código

El Ciclo TDD

ROJO
Escribe un test que falle

VERDE
Escribe el código mínimo

REFACTOR
Mejora el código sin romper tests

Aplicación en IA / ML

XP es vital para asegurar la **calidad de los pipelines** de datos y entrenamiento, donde los errores son silenciosos y costosos.

- **Tests de Datos:** Verificar que los datos de entrada cumplan el esquema esperado (Great Expectations).
- **Tests de Transformación:** Asegurar que el preprocesamiento (normalización, encoding) sea correcto.
- **Pair Programming:** Un Data Scientist y un ML Engineer trabajando juntos para optimizar modelos.

CRISP-DM: El Estándar en IA

El Estándar de Oro

Diseñado específicamente para Minería de Datos e IA. A diferencia de Cascada, es **cíclico y flexible**: permite volver atrás si los datos no son suficientes o el modelo no rinde.

Ejemplo: Predicción de Churn

Telecom

1. **Negocio:** "Queremos reducir la pérdida de clientes un 10%."
2. **Datos:** Recopilar historial de llamadas, quejas y pagos.
3. **Preparación:** Limpiar nulos, normalizar valores, crear features.
4. **Modelado:** Entrenar Random Forest y XGBoost.
5. **Evaluación:** ¿El Recall es suficiente? ¿Detectamos a los que se van?
6. **Despliegue:** Integrar modelo en CRM para alertar a ventas.

MLOps (Machine Learning Operations)

Reproducibilidad
Código, Datos y Entorno

Automatización
Pipelines CI/CD/CT

Monitoreo
Drift y Performance

Concepto Clave: Data Drift
El mundo cambia, tus datos cambian. Si no re-entrenas, la precisión de tu modelo **se degrada** con el tiempo.

Analogía
Como tener un coche: no basta con comprarlo (desplegarlo), necesitas mantenimiento continuo, cambio de aceite y revisiones (MLOps).

Ciclo continuo: El trabajo no termina en el despliegue

Caso Real: Netflix
Recomiendan películas basándose en lo que ves HOY. Usan MLOps para actualizar sus modelos diariamente con nuevos datos de usuarios.

Comparativa General de Modelos

MODELO	FLEXIBILIDAD	DOCUMENTACIÓN	IDEAL PARA IA	COMPLEJIDAD
Cascada	Baja	Alta	No Recomendado	Baja
Modelo en V	Baja	Alta	Parcial	Media
Iterativo / Incr.	Alta	Media	Adecuado	Media
Espiral	Alta	Alta	Excelente	Alta
Scrum	Muy Alta	Variable	Adaptable	Media
Kanban	Muy Alta	Baja	Excelente (Ops)	Baja
XP (Extreme)	Alta	Baja	Limitado	Alta
CRISP-DM	Alta	Media	Estándar	Media
MLOps	Media	Automática	Crítico (Prod)	Muy Alta

¿Cuándo usar cada modelo?

Proyecto Académico / Tesis

CRISP-DM + Iterativo

Enfocado en la investigación y experimentación. Necesitas una estructura clara para el análisis de datos (CRISP-DM) y ciclos de mejora (Iterativo).

Startup con IA

Scrum + CRISP-DM

Velocidad y adaptación al mercado. Usa Scrum para gestionar entregas rápidas y CRISP-DM para estructurar el trabajo de Data Science dentro de los sprints.

Empresa (Modelos en Producción)

Kanban + MLOps

Gestión continua. Kanban maneja el flujo de mantenimiento y peticiones, mientras MLOps automatiza el ciclo de vida, monitoreo y reentrenamiento.

Sistema Crítico (Salud/Aviación)

Espiral + Modelo en V

Seguridad ante todo. Espiral gestiona los altos riesgos éticos y técnicos, y el Modelo en V asegura una validación y verificación rigurosa antes del despliegue.

Mensaje Clave: En la práctica, los equipos exitosos COMBINAN modelos según su contexto.

Caso Práctico: Detector de SPAM

El Desafío

Tu empresa de email marketing necesita integrar un sistema de detección de spam con IA para limpiar sus listas de correo antes del envío.

01 Negocio

Objetivo: Reducir la tasa de spam en un 90% para evitar bloqueos de IP.
KPI: False Positives < 0.1%.

02 Datos

Recolección de **100,000 emails** históricos. Etiquetado manual: *"Spam"* vs *"Legítimo"*.

03 Preparación

Limpieza de HTML, eliminación de stopwords. **Tokenización** y vectorización (TF-IDF o Embeddings).

04 Modelado

Entrenamiento de candidatos:

- Naive Bayes (Baseline)
- Random Forest
- BERT (Deep Learning)

05 Evaluación

Comparar métricas en test set: **Precision vs Recall**. Priorizar Precision para evitar borrar emails legítimos.

06 Despliegue

Exponer modelo vía **API REST** (Docker). Configurar sistema de monitoreo de *Data Drift*.

DISCUSIÓN ¿Qué metodología de gestión de proyecto usarías para coordinar al equipo durante estos 6 pasos? (¿Scrum? ¿Kanban?)

Caso Práctico: App de Recomendaciones

Escenario: Startup "MoodMusic"

Crear una app que recomiende canciones según el estado de ánimo del usuario usando IA.

Scrum + CRISP-DM

Sprint 1 — **SPIKE: Investigación y Datos** CRISP: Datos

Conexión a Spotify API, descarga de dataset inicial, análisis exploratorio (EDA) y limpieza de datos.

Sprint 2 — **Modelo Base (MVP)** CRISP: Modelado

Entrenamiento de modelo de clasificación simple (Random Forest). Validación de métricas offline (Accuracy).

Sprint 3 — **Integración y App** CRISP: Despliegue

Creación de API REST con el modelo. Integración con frontend móvil. Pruebas de integración.

Sprint 4 — **Feedback Loop** MLOps

Implementación de recolección de feedback (Likes/Dislikes) y pipeline de reentrenamiento automático.

Tablero del Equipo

Snapshot: Sprint 2 (Semana 1)

POR HACER	EN PROGRESO	HECHO
Backend Crear endpoint para ingesta de datos en tiempo real	ML Entrenando modelo Random Forest v1.0	Data Limpieza de nulos en columnas de género
ML Investigar hiperparámetros para XGBoost	Data Validación de calidad del dataset de prueba	Infra Setup del entorno de Jupyter Notebooks

Riesgos en Proyectos de IA

La IA introduce niveles de incertidumbre que el software tradicional no tiene. Identificar estos riesgos temprano es crucial.

Riesgo de Datos

La calidad del output depende totalmente del input ("Garbage in, garbage out").

¿Tienes suficientes datos? ¿Son de calidad?

Riesgo del Modelo

Incertidumbre sobre si el algoritmo podrá aprender los patrones necesarios.

¿Es el ML capaz de resolver este problema?

Riesgo Ético

Posibilidad de que el modelo discrimine o genere sesgos injustos.

¿El modelo discrimina por género o raza?

Riesgo de Integración

Desafíos técnicos al llevar el modelo a producción (latencia, costes).

¿Funciona rápido y escala con usuarios reales?

Riesgo Regulatorio

Cumplimiento de leyes como GDPR, CCPA o normativas locales de IA.

¿Cumple con la protección de datos?

La Solución: Modelo en Espiral

Diseñado específicamente para gestionar estos riesgos mediante ciclos de análisis antes de construir.

Actividad en Clase

Elige UNO de estos escenarios:

App de Salud con IA

Sistema de diagnóstico preliminar basado en síntomas e historial.

Conducción Autónoma

Software para vehículo que toma decisiones en tiempo real.

Chatbot NLP

Atención al cliente automatizada para resolver quejas complejas.

Precios Dinámicos

E-commerce que ajusta precios según demanda y competencia.

Grupos de 3-4
Formen equipos rápidamente

Pitch de 5 min
Al finalizar el tiempo

Entregables (A responder):

1. **Modelo Elegido y Por Qué**
   ¿Cascada? ¿Scrum? ¿Espiral? Justifiquen basándose en la incertidumbre.
2. **Top 3 Riesgos**
   Identifiquen riesgos específicos (ej. sesgo de datos, seguridad, latencia).
3. **Adaptaciones para IA**
   ¿Cómo cambia el proceso tradicional? (Datasets, métricas, MLOps).

Resumen

01

Modelos Clásicos

Cascada y V son estructurados y predecibles, pero **rígidos** ante cambios. Útiles solo cuando los requisitos son fijos y conocidos.

02

Modelos Ágiles

Scrum, Kanban y XP priorizan la **flexibilidad** y la entrega continua. Se adaptan mejor a la evolución rápida del software moderno.

03

El Estándar para IA

CRISP-DM define el proceso científico de minería de datos.

MLOps operacionaliza el ciclo de vida del modelo.

Juntos, son la base indispensable para proyectos de Inteligencia Artificial exitosos.

04

Incertidumbre en IA

A diferencia del software tradicional, en IA **no sabes si funcionará** hasta que entrenas. Necesitas procesos que toleren el fallo y la experimentación.

05

Contexto es Rey

No existe una "bala de plata". En la práctica, los equipos exitosos **combinan modelos** (ej. Scrum + CRISP-DM) según las necesidades del proyecto.

Preguntas Frecuentes

¿Por qué Cascada NO es adecuado para IA?

Porque la IA tiene **alta incertidumbre**. Cascada es rígido y no permite volver atrás si el modelo falla al final.

¿Qué es un SPIKE en Scrum?

Es un **Sprint de investigación** (time-boxed) usado para estimar esfuerzo técnico o probar viabilidad antes de desarrollar.

¿Qué es Data Drift?

Es la **degradación del modelo** que ocurre cuando los datos del mundo real cambian respecto a los datos de entrenamiento.

¿Diferencia entre Iterativo e Incremental?

Iterativo = **mejorar** lo existente (refinar).
Incremental = **añadir** nuevas partes funcionales (construir por piezas).

¿Cuándo usar el Modelo en Espiral?

En proyectos grandes con **riesgos críticos** (seguridad, ética, costes) donde el análisis de riesgos es la prioridad número uno.