

Consideraciones Especiales para Proyectos de IA



Calidad
de Datos



Selección
del Modelo



Ética
en IA



Interpre-
tabilidad



Aprendizaje
Continuo

1



Calidad de los Datos

"Garbage In, Garbage Out" — el principio más importante en IA

¿Qué hace buenos a tus datos?



GIGO

Garbage In
Garbage Out



Relevancia

Los datos deben reflejar el problema real



Exactitud

Sin errores de captura o medición



Compleitud

Suficientes ejemplos de todas las clases



Balance

Proporciones razonables entre categorías



Unicidad

Sin duplicados — un dato por observación

Pipeline de preparación de datos

1. EDA



2. Limpieza



3. Nulos



4. Balanceo




5. Normalizar



6. Train/Val/Test

Ejemplo Real: Detector de Spam



■ Correos normales (95%) ■ Spam (5%)

⚠ El Problema

Un dataset con 9,500 correos normales y solo 500 spam. El modelo aprende a decir siempre "no es spam" y logra 95% de exactitud... ¡sin aprender nada útil!

✓ La Solución

- **SMOTE**: Genera ejemplos sintéticos de la clase minoritaria
- **Undersampling**: Reduce la clase mayoritaria
- **Pesos de clase**: Penaliza más los errores en spam

🔔 **Error Frecuente: Data Leakage** — Normalizar TODO el dataset ANTES de dividir en train/test contamina el modelo con información del futuro. Siempre divide primero, normaliza después usando solo las estadísticas del train set.



Pregunta de Reflexión #1

Calidad de Datos

Imagina que quieres crear un sistema de IA para detectar enfermedades en radiografías de pulmón. El hospital solo tiene radiografías de pacientes mayores de 60 años.

¿Qué problema tendría tu modelo si lo usaras también en pacientes jóvenes?
¿Cómo lo resolverías?

2



Selección del Modelo

No existe un modelo universal — el mejor depende del problema

¿Qué modelo usar según el problema?

Tipo de Problema	Modelos Recomendados	Ejemplo de Uso
Clasificación binaria	Logística, SVM, XGBoost	Spam / No spam
Clasificación multi-clase	CNN, Softmax, Transformers	Reconocimiento de imágenes
Regresión	Reg. Lineal, Gradient Boosting	Predicción de precios
Series de tiempo	ARIMA, LSTM, Transformer	Ventas mensuales
Texto (NLP)	BERT, GPT, Word2Vec+LSTM	Chatbots, sentimiento
Imágenes	ResNet, YOLO, U-Net	Diagnóstico médico
Datos tabulares	XGBoost, LightGBM, RF	Datos empresariales



Navaja de Occam en IA:

Prefiere siempre el modelo MÁS SIMPLE que resuelva el problema con la precisión requerida. Empieza con regresión logística o un árbol de decisión antes de ir a redes neuronales.

Ejemplo: Predictor de Deserción Escolar

🎓 Tu universidad quiere predecir qué estudiantes tienen riesgo de abandonar la carrera usando datos tabulares: calificaciones, asistencia, actividades extracurriculares y situación socioeconómica.

❌ Opción A — Red Neuronal Profunda

- Requiere miles de registros para aprender bien
- Difícil de interpretar (caja negra)
- Necesita GPU para entrenar rápido
- La rectoría no entenderá por qué marcó a un alumno
- Mucho tiempo de desarrollo y ajuste



✅ Opción B — Random Forest / XGBoost

- Funciona bien con cientos de registros
- Entrega importancia de variables (interpretable)
- Entrena en segundos en CPU normal
- Puedes decir: calificaciones y asistencia son clave
- Fácil de mantener y actualizar



Pregunta de Reflexión #2

Selección del Modelo

Tienes un dataset de 300 registros médicos para predecir si un paciente desarrollará diabetes en los próximos 5 años.

Un compañero propone usar GPT-4 fine-tuned. ¿Estás de acuerdo? Justifica qué modelo usarías tú y por qué.

3



Consideraciones Éticas

La IA no es neutral — hereda los sesgos de los datos y de sus creadores

Los 5 Principios Éticos Fundamentales



Justicia

El sistema no debe discriminar por raza, género, edad u otra característica protegida.

→ Verificar métricas por subgrupos de población



Transparencia

Los usuarios deben saber que interactúan con IA y conocer sus limitaciones.

→ Avisos claros, interfaces honestas



Privacidad

Proteger los datos personales de los usuarios en todo momento.

→ Anonimización, cumplir LFPDPPP / GDPR



Responsabilidad

Siempre debe existir un humano responsable de las decisiones del sistema.

→ Logs, auditorías, revisión humana



No Maleficencia

El sistema no debe causar daño intencional ni accidental a ninguna persona.

→ Pruebas exhaustivas, análisis de riesgos

El Caso Amazon: IA con sesgo de género

2014



Amazon desarrolla sistema de IA para filtrar CVs de candidatos

2015



El modelo se entrena con CVs de empleados contratados en los últimos 10 años

2016



Se detecta que el modelo penaliza la palabra 'mujeres' en los CVs

2017



El modelo prefiere verbos asociados históricamente con candidatos masculinos

2018



Amazon abandona el proyecto. La IA aprendió sesgos históricos



Lección clave: Los datos históricos reflejan sesgos históricos. Tu modelo los aprenderá si no intervienes activamente durante el diseño.




Pregunta de Reflexión #3

Consideraciones Éticas

Estás desarrollando un sistema de IA para que los bancos aprueben o rechacen préstamos de forma automática.

¿Qué tipos de sesgo podrían aparecer? ¿Cómo diseñarías el sistema para que sea justo con todas las personas?

4




Interpretabilidad del Modelo

XAI — Explainable Artificial Intelligence

¿Cómo saber por qué tu modelo decide así?

ESPECTRO DE INTERPRETABILIDAD



SHAP

Cuantifica la contribución de CADA variable a UNA predicción específica. Basado en teoría de juegos. Compatible con casi cualquier modelo.



LIME

Genera una explicación LOCAL aproximando el modelo con uno simple alrededor de una instancia. Útil para entender casos individuales.



Grad-CAM

Para redes convolucionales. Genera mapas de calor sobre imágenes mostrando qué regiones activaron la predicción del modelo.



`pip install shap` | `pip install lime` | `pip install grad-cam`

Ejemplo: Diagnóstico de Neumonía con CNN

🫁 Una CNN (Red Neuronal Convolutacional) detecta neumonía en radiografías con 94% de precisión. El médico pregunta: ¿en qué parte del pulmón basa el diagnóstico? Usamos Grad-CAM para generar un mapa de calor...

✓ Escenario Bueno



El mapa de calor resalta los lóbulos pulmonares — exactamente donde debería. El médico confía en el diagnóstico y el modelo es desplegado en el hospital.



✗ Shortcut Learning



El mapa resalta la ETIQUETA de la radiografía, no los pulmones. El modelo aprendió que las radiografías con cierta etiqueta son positivas. 94% de precisión... sin diagnóstico real.

Sin Grad-CAM nunca habríamos descubierto el Shortcut Learning — alta precisión no garantiza que el modelo aprendió lo correcto.



Pregunta de Reflexión #4

Interpretabilidad

Un sistema de IA decide automáticamente a qué estudiantes dar becas universitarias.

Obtiene 91% de precisión.

¿Es suficiente con saber que funciona bien? ¿Qué pasa si el modelo rechaza a un estudiante y este pregunta por qué?

5



Aprendizaje Continuo

Los modelos se vuelven obsoletos — el mundo cambia, los datos también

Model Drift y Estrategias de Actualización



Data Drift

La distribución de los datos de entrada cambia.
Ej: los patrones de fraude evolucionan constantemente con nuevas técnicas.



Concept Drift

La relación entre variables y resultado cambia.
Ej: comportamiento de compra durante pandemia vs. época normal.



Label Drift

La definición de las clases cambia. Ej: qué se considera 'spam' varía con el tiempo y los nuevos tipos de correo.

ESTRATEGIAS DE ACTUALIZACIÓN


Estrategia	Cómo funciona	Ventaja	Desventaja
Reentrenamiento periódico	Reentrenar completo con datos nuevos + históricos	Simple de implementar	Costoso en tiempo y cómputo
Fine-tuning incremental	Continuar entrenamiento con datos nuevos solamente	Más eficiente	Riesgo de Catastrophic Forgetting
Ventana deslizante	Solo los N datos más recientes para reentrenar	Se adapta muy rápido	Pierde contexto histórico
Ensemble dinámico	Combinar modelo antiguo con uno nuevo	Equilibrado y robusto	Mayor complejidad operacional



Catastrophic Forgetting: al actualizar con datos nuevos, el modelo puede olvidar lo aprendido antes. Solución: Elastic Weight Consolidation (EWC) o replay buffers.

Ejemplo: Recomendador de Películas

Oct 2024



Entrenas el modelo con
historial de visualizaciones
hasta esa fecha

Nov 2024



Sale una película viral que
domina las conversaciones de
los usuarios

Ene 2025



El modelo no puede
recomendarla — nunca la vio
en el entrenamiento

Mar 2025



Los usuarios reciben
recomendaciones obsoletas. El
sistema pierde relevancia

✓ La Solución: MLOps con monitoreo continuo

Data pipelines automáticos • Monitoreo de métricas en tiempo real • Versionado de modelos (MLflow, DVC) • CI/CD para ML • Rollback automático



Pregunta de Reflexión #5

Aprendizaje Continuo

Un sistema de IA que detecta noticias falsas fue entrenado en 2022. Ahora es 2025 y los creadores de contenido usan nuevas técnicas de desinformación que el modelo no conoce.

¿Qué estrategia de actualización elegirías y con qué frecuencia actualizarías el modelo?

Los 5 Pilares de un Proyecto de IA Exitoso



1. Calidad de Datos

Limpia, balancea y valida antes de entrenar. Divide primero, normaliza después.



2. Selección del Modelo

Empieza simple. Añade complejidad solo cuando la necesites y puedas justificarla.



3. Ética en IA

Identifica sesgos, protege la privacidad y documenta cada decisión de diseño.



4. Interpretabilidad

Usa SHAP, LIME o Grad-CAM. Alta precisión no implica que el modelo aprendió lo correcto.



5. Aprendizaje Continuo

Monitorea el drift. Actualiza el modelo periódicamente con una estrategia MLOps.

*"Un buen ingeniero de IA no solo construye modelos que funcionan,
sino modelos que son responsables, explicables y sostenibles en el tiempo."*