Ciclo de Vida del Software en Proyectos de IA

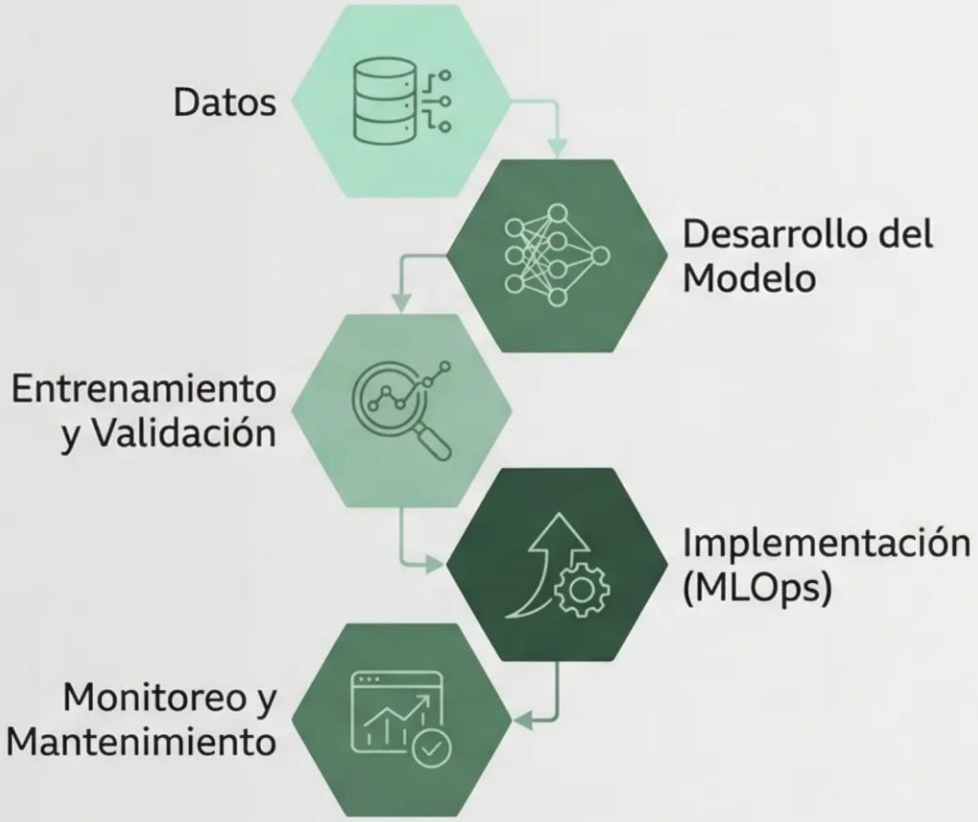

¿Sera lo mismo un desarrollo tradicional sobre un

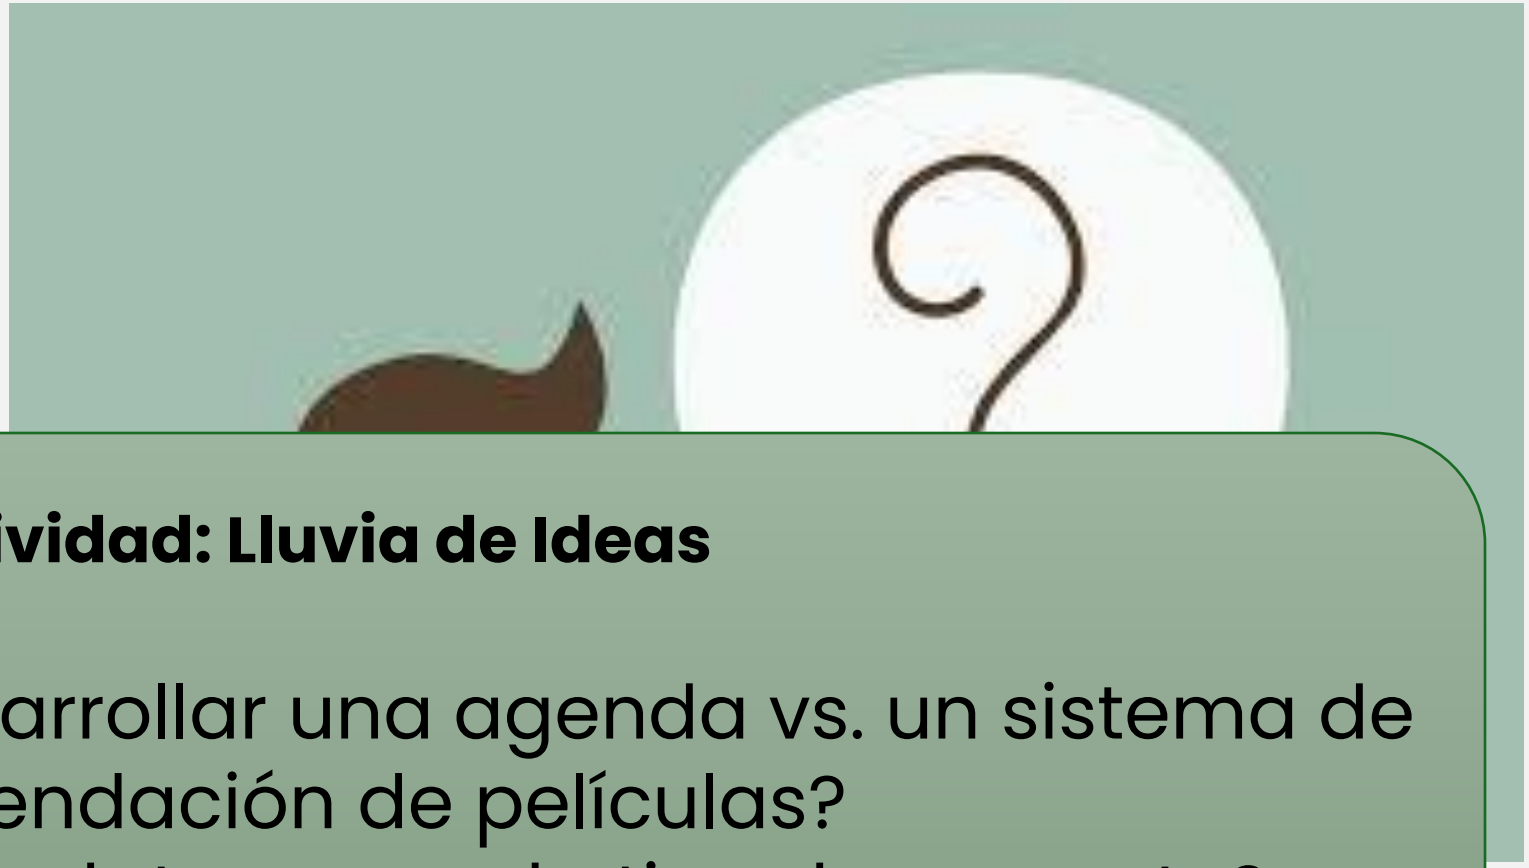

Actividad: Lluvia de Ideas

¿Diferencias entre desarrollar una agenda vs. un sistema de recomendación de películas?
¿Qué rol juegan los datos en cada tipo de proyecto?
¿Es igual el mantenimiento en ambos casos?

SDLC Tradicional vs. Ciclo de Vida de IA

SDLC Tradicional

Ciclo de Vida de IA

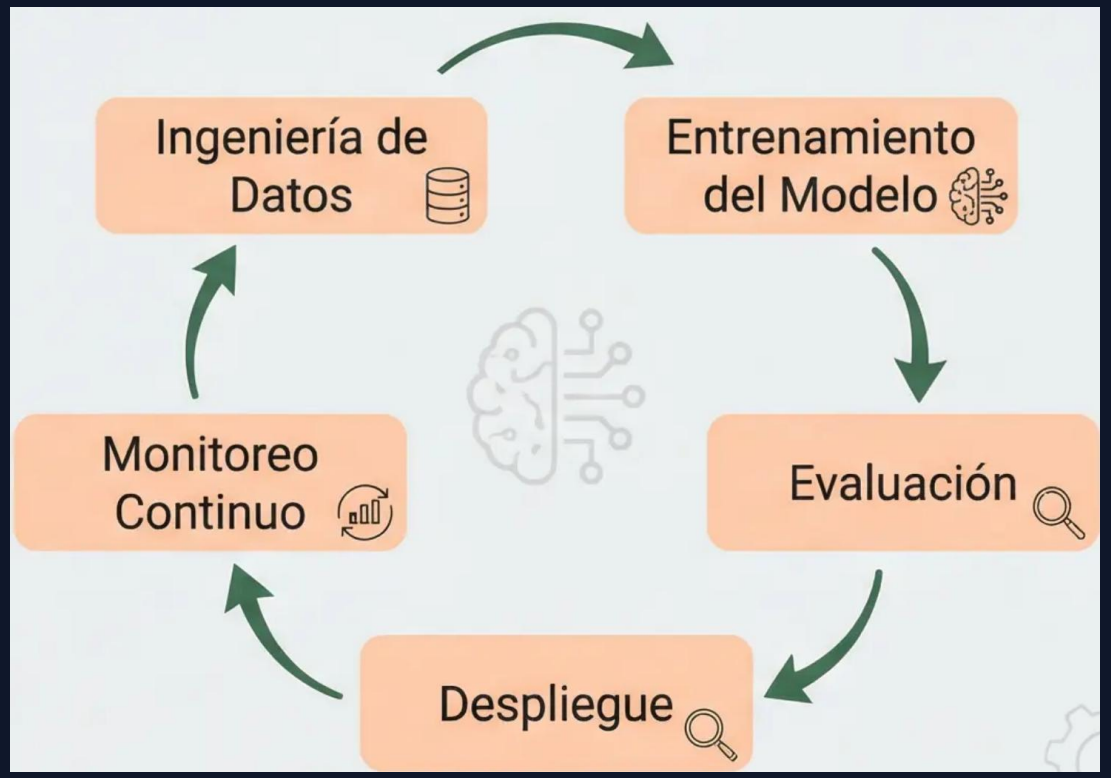

¿Por qué la IA es diferente del desarrollo tradicional?

Basado en Datos, no Reglas

No codificamos la lógica explícitamente (if-else); el sistema aprende patrones a partir de ejemplos históricos.

Probabilístico vs Determinista

El software tradicional da siempre la misma respuesta. La IA opera con incertidumbre y porcentajes de confianza.

Experimental e Iterativo

El desarrollo no es lineal. Requiere experimentación constante con algoritmos, parámetros y datos.

Entorno Dinámico (Drift)

Los datos del mundo real cambian. Un modelo preciso hoy puede fallar mañana si no se actualiza.

Programación Tradicional

Reglas
Datos
→ Respuestas

"Nosotros definimos la lógica"

↓

Cambio de Paradigma

Machine Learning

Datos
Respuestas
→ Reglas (Modelo)

"El sistema aprende la lógica"

Este cambio fundamental exige pasar de DevOps a MLOps.

Las 6 Fases del Ciclo de Vida de IA

Un proceso iterativo y cíclico, no una línea recta.

Etapa Inicial Crítica

Fase 1: Definición del Problema y Viabilidad de Datos

Antes de modelar, debemos asegurar que la pregunta es correcta y los datos existen.

Alineación con Negocio

Definir claramente qué dolor del negocio resuelve la IA. Establecer KPIs de impacto (ej. reducción de fraude en 5%).

1

Hipótesis de Valor

¿Por qué usar IA? Confirmar que la heurística tradicional no basta y que el ML aporta una ventaja real.

2

Métrica de Éxito

Definir la métrica técnica (Accuracy, F1-Score) y el umbral mínimo aceptable para el despliegue.

3

Viabilidad de Datos

¿Existen los datos? ¿Son accesibles? ¿Son representativos de la realidad futura? Sin datos, no hay IA.

4

Riesgos y Ética

Identificar posibles sesgos en los datos históricos, restricciones de privacidad (GDPR) y riesgos de seguridad.

5

Entregables Clave

Documento de alcance (Project Charter), Contrato de Datos preliminar y Plan de Validación.

6

La Fase Más Crítica (80% del Esfuerzo)

Fase 2: Recopilación y Preparación de Datos

Calidad sobre cantidad: Los datos son el combustible del sistema y determinan el límite superior del rendimiento.

Fuentes de Datos

Identificar y conectar orígenes diversos: bases de datos SQL/NoSQL, APIs externas, logs de sensores IoT o scrapping web.

1

Almacenamiento

Ingesta en Data Lakes (datos crudos y no estructurados) para flexibilidad, o Data Warehouses (estructurados) para consistencia.

2

Limpieza y Preprocesado

El paso más laborioso: imputar nulos, eliminar duplicados, corregir tipos de datos y manejar outliers que distorsionan el aprendizaje.

3

Análisis Exploratorio (EDA)

Visualizar distribuciones y correlaciones para entender la naturaleza de los datos, detectar sesgos ocultos y anomalías.

4

Ingeniería de Características

Transformar datos brutos en features informativas (Feature Engineering): normalización, one-hot encoding y creación de variables sintéticas.

5

Buenas Prácticas

Implementar Data Versioning (DVC), crear Data Cards documentadas y asegurar la trazabilidad del linaje del dato.

6

Actividad 1: Calidad de Datos

Identificación de problemas en datasets del mundo real

Objetivo

Analizar un mini-dataset defectuoso para desarrollar el "ojo crítico" necesario antes de la etapa de modelado. Detectar problemas ocultos que romperían el entrenamiento.

Instrucciones Paso a Paso

1. **Análisis Exploratorio Rápido**
   Revisen el dataset proporcionado. Busquen visualmente valores extraños (ej. edad: -5, nulos).

2. **Identificación de Patologías**
   Detecten al menos un caso de: Valores Faltantes, Desbalance de Clases, Outliers Extremos y Sesgo de Muestreo.

3. **Propuesta de Solución**
   Para cada problema, decidan una estrategia: ¿Eliminar? ¿Imputar (media/moda)? ¿Recolectar más datos?

Entregable Final

Una lista priorizada de **3 acciones correctivas** inmediatas para limpiar el dataset.
Cada equipo compartirá su hallazgo más crítico al final (Debrief).

Dataset

Contexto
Empresa de e-commerce que quiere predecir si un cliente hará una recompra.

ID	Edad	Ciudad	Ingresos	Historial_Compras	Tiempo_Web_Min	Metodo_Pago	Recompra
1	25	CDMX	15000	5	30	Tarjeta	Sí
2	-5	Guadalajara	18000	3	25	Tarjeta	Sí
3	40	Monterrey	NULL	10	50	PayPal	Sí
4	22	CDMX	12000	1	5	Efectivo	No
5	35	Puebla	2000000	2	15	Tarjeta	No
6	28	CDMX	14000	4	NULL	Tarjeta	Sí
7	19	CDMX	9000	0	3	Efectivo	No
8	120	Monterrey	17000	7	40	Tarjeta	Sí
9	32	Guadalajara	16000	6	35	Bitcoin	Sí
10	30	CDMX	15000	5	30	Tarjeta	Sí
11	30	CDMX	15000	5	30	Tarjeta	Sí
12	NULL	Puebla	11000	2	20	Tarjeta	No
13	27	CDMX	13000	3	22	Tarjeta	Sí
14	29	Monterrey	12500	1	8	Efectivo	No
15	45	Guadalajara	21000	8	60	Tarjeta	Sí

Fase 3: Ingeniería y Entrenamientodel Modelo de IA

El corazón del proceso: donde los algoritmos aprenden patrones de los datos preparados mediante iteraciones experimentales.

Selección de Algoritmos

Elegir el enfoque adecuado (ej. Redes Neuronales, Random Forest, XGBoost) basado en el tipo de problema (clasificación, regresión).

1

Particiones de Datos

División estratégica en conjuntos de Entrenamiento (aprender), Validación (ajustar) y Prueba (evaluar final) para medir generalización.

2

Ajuste de Hiperparámetros

Optimización de configuraciones externas (Learning Rate, Batch Size, Profundidad) para maximizar el rendimiento del modelo.

3

Prevención de Overfitting

Aplicación de técnicas de regularización (L1/L2, Dropout) para evitar que el modelo "memorice" el ruido de los datos de entrenamiento.

4

Registro de Experimentos

Tracking riguroso de cada ejecución (MLflow, Weights & Biases) asegurando reproducibilidad de código, datos y parámetros.

5

Resultados Preliminares

Selección del "Modelo Candidato" que muestra las mejores métricas en validación para avanzar a la fase de evaluación profunda.

6

Fase 4: Evaluación y Validación

Más allá de la precisión simple: asegurando que el modelo es justo, robusto y útil para el negocio.

Métricas de Rendimiento

Seleccionar la métrica correcta (Accuracy, Precision, Recall, F1-Score, AUC) basándose en el costo del error.

1

Matriz de Confusión

Visualizar errores tipo I (falsos positivos) y tipo II (falsos negativos) para entender dónde falla el modelo.

2

Evaluación por Subgrupos

Desglosar el rendimiento por segmentos (edad, región, género) para detectar sesgos ocultos en promedios globales.

3

Umbrales de Decisión

Ajustar el umbral de probabilidad (ej. >0.7 en vez de >0.5) para optimizar el balance precisión-recall según el negocio.

4

Interpretabilidad (XAI)

Utilizar técnicas como SHAP o LIME para explicar por qué el modelo tomó una decisión específica.

5

Checklist de Producción

Validar latencia, uso de recursos, seguridad y cumplimiento antes de aprobar el paso a despliegue.

6

Debate Abierto

Actividad 2: Debate sobre Sesgos

Dilemas éticos y técnicos en la validación de modelos

Logística

7-8 Minutos
Tiempo de discusión

Dinámica
Equipos o Plenaria

"Un modelo puede ser preciso matemáticamente, pero injusto socialmente."

Objetivo

Reconocer y mitigar sesgos algorítmicos. Entender que "mayor precisión global" no siempre significa "mejor modelo" si sacrifica a un subgrupo.

Caso de Estudio: El Modelo de Crédito

Escenario: Han entrenado un modelo para aprobar préstamos. La **Exactitud (Accuracy) global es del 95%**. Sin embargo, al auditarlo, descubren que el **Recall (Sensibilidad)** para solicitantes menores de 25 años es solo del **60%**.

? **Priorización de Métricas**

¿Qué métrica priorizarían en este contexto de negocio y por qué? ¿Es aceptable el 60%?

? **Medición de Fairness**

¿Cómo medirían la "justicia" (fairness) antes y después de desplegar? ¿Qué tests aplicarían?

? **Acciones de Mitigación**

¿Qué cambios aplicarían? ¿Revisar los datos de entrenamiento? ¿Ajustar umbrales por edad?

Conclusión Esperada

Acordar una estrategia de corrección: ¿Es un problema de datos (falta representatividad) o de modelado?

Fase 5: Despliegue a Producción y Operacionalización

Hacer que el modelo esté disponible para usuarios finales y genere valor de negocio real.

Patrones de Despliegue

Selección estratégica entre inferencia en lote (Batch), tiempo real (API REST/gRPC) o embebido en dispositivos (Edge AI).

Infraestructura y Contenedores

Uso de Docker y Kubernetes para empaquetar modelos y dependencias, garantizando portabilidad y escalabilidad.

Estrategias de Release

Implementación segura mediante técnicas como Canary Deployment, Blue-Green o Shadow Mode para minimizar riesgos.

CI/CD para ML

Pipelines automatizados de Integración y Despliegue Continuo específicos para validar y lanzar modelos.

Observabilidad

Monitorización profunda de latencia, errores y consumo de recursos (CPU/GPU) en el entorno productivo.

Rollback y Versionado

Capacidad para gestionar versiones del modelo y revertir cambios instantáneamente ante fallos en producción.

Monitorización, Mantenimiento y Reentrenamiento

El despliegue no es el final. Es el comienzo de la degradación del modelo (Model Drift).

Día 0: Despliegue

Baseline & Alertas

Establecer línea base de rendimiento.

Configurar alertas de latencia y errores (HTTP 500).

Smoke tests en producción.

Semanas 1 - 4

Detección de Drift

Data Drift: ¿Cambió la distribución de input?

Concept Drift: ¿Cambió la relación X->Y?

Monitorizar calidad de datos de entrada.

Mes 1 - 3

Evaluación de Negocio

Medir impacto real en KPIs (ROI, conversión).

Revisar sesgos con nuevos datos reales.

Ajustar umbrales de reentrenamiento.

Proceso Continuo

Ciclo de Feedback

Recolección de datos fallidos (Edge cases).

Re-etiquetado manual (Human-in-the-loop).

Entrenamiento automático (CT) y despliegue (CD).

Advertencia: Sin reentrenamiento, la precisión de un modelo puede caer un 10-20% en pocos meses debido a cambios en el entorno.

SDLC Tradicional vs Ciclo de Vida de IA

Un cambio fundamental de paradigma: del determinismo a la probabilidad

DIMENSIÓN	SOFTWARE TRADICIONAL	INTELIGENCIA ARTIFICIAL
Naturaleza	**Determinista**: Mismo input, siempre mismo output.	**Probabilística**: Resultados con % de confianza.
Requisitos	Fijos y definidos a priori (Especificaciones).	Experimentales e **hipótesis** iterativas.
Fuente de Verdad	La lógica explícita en el **Código**.	Datos + Código + Parámetros.
Desarrollo	Lineal / Construcción de funcionalidades.	Científico / **Entrenamiento** (Prueba y Error).
Pruebas	Unitarias / Integración (Pasa/Falla).	Validación Estadística (Accuracy, F1, Recall).
Mantenimiento	Corrección de bugs esporádica.	Monitorización continua de **Drift** y Reentrenamiento.
Criterio de Éxito	Cumplimiento funcional de requisitos.	Impacto en **métricas de negocio** y generalización.

Metodología Transversal

MLOps: Operacionalizar y Escalar IA
La convergencia de DevOps y Machine Learning

Un marco de trabajo para automatizar, monitorizar y gestionar el ciclo de vida de los modelos de forma eficiente.

1

Automatización del Ciclo

Eliminación de procesos manuales propensos a errores. Desde la ingesta de datos hasta el despliegue, buscando flujos de trabajo repetibles y eficientes.

2

Pipelines CI/CD/CT

Extensión de CI/CD para ML: Integración Continua, Entrega Continua y **Entrenamiento Continuo** (CT) para mantener los modelos actualizados.

3

Versionado Total

No solo versionamos código (Git). MLOps exige versionar Datos (DVC) y Modelos (MLflow) para garantizar la trazabilidad y reversibilidad.

4

Monitorización 360°

Supervisión en producción más allá de "funciona/no funciona". Detección de Data Drift, Concept Drift y degradación del rendimiento en tiempo real.

5

Gobernanza y Ética

Control de acceso, auditoría de modelos, cumplimiento normativo (GDPR) y detección de sesgos automatizada en el pipeline.

6

Velocidad y Calidad

El objetivo final: reducir el Time-to-Market de meses a semanas, asegurando modelos robustos, escalables y de alta calidad.

Gobernanza, Ética y Mejores Prácticas

Construyendo una IA responsable, sostenible y alineada con los valores corporativos.

Gobernanza de Modelos

Establecer políticas claras de acceso a datos, auditorías periódicas y asignar responsables directos (Data Stewards) para cada modelo.

Ética y Responsabilidad

Garantizar equidad (fairness), transparencia y explicabilidad. Mitigar sesgos algorítmicos que puedan discriminar a subgrupos.

Cumplimiento Normativo

Adhesión estricta a regulaciones (GDPR, EU AI Act), gestión segura de consentimientos y protección de datos sensibles.

Metodologías Ágiles

Adoptar marcos como Scrum o Kanban para permitir iteraciones rápidas y adaptarse a la naturaleza experimental del Machine Learning.

Registro de Decisiones

Documentar rigurosamente cada experimento, métrica y versión del modelo para mantener la trazabilidad completa del ciclo de vida.

Equipos Multidisciplinares

Fomentar la colaboración entre Científicos de Datos, Ingenieros MLOps y expertos de negocio para asegurar el éxito del despliegue.

Riesgos y Soluciones

Desafíos Comunes y Mitigaciones

Obstáculos frecuentes en proyectos de IA y estrategias efectivas para superarlos.

Datos de Baja Calidad

Datos incompletos, ruidosos o sesgados que llevan a modelos inútiles ("Garbage In, Garbage Out").

Mitigación: Auditorías de datos, Data Contracts y herramientas de validación automática (Great Expectations).

Del Prototipo a Producción

Dificultad para escalar notebooks experimentales a sistemas robustos y de baja latencia.

Mitigación: Adopción de MLOps, contenedores (Docker) y estandarización de pipelines CI/CD.

Deriva del Modelo (Drift)

Degradación del rendimiento por cambios en los datos de entrada o en el concepto a predecir.

Mitigación: Monitorización continua en tiempo real y estrategias de reentrenamiento automático.

Equipos y Cultura

Silos entre Data Scientists, Ingenieros y Negocio. Falta de comunicación y expectativas irreales.

Mitigación: Equipos multidisciplinares (Squads), formación cruzada y metodologías ágiles.

Costes y Rendimiento

Modelos complejos (Deep Learning) costosos de entrenar y lentos en inferencia.

Mitigación: Optimización de modelos (quantization, pruning), selección de instancias adecuadas y control de costes cloud.

Clave del Éxito

La anticipación es fundamental. Diseñar el sistema pensando en que fallará y necesitará evolucionar.

Discusión

Actividad 4: Reflexión Final

Debate estratégico: Think - Pair - Share

Logística

6-8 Minutos
Tiempo de debate

Formato
Parejas / Plenaria

"La tecnología es fácil; la gente y los procesos son difíciles."

Objetivo

Sintetizar los aprendizajes de la sesión aplicando el pensamiento crítico a dilemas comunes en proyectos reales de IA.

Preguntas Disparadoras

Fases Subestimadas
¿Qué fase del ciclo de vida (Datos, Modelado, Despliegue, Monitorización) crees que se subestima más en la práctica y por qué?

Métricas Prioritarias
Más allá del *accuracy* técnico, ¿qué métrica de negocio o ética priorizarías en tu proyecto actual?

Gobernanza Ágil
¿Cómo introducirías controles de gobernanza sin frenar la velocidad de innovación del equipo de Data Science?

Alerta "Día 0"
Si desplegaras hoy, ¿cuál sería la primera alerta crítica que configurarías en el sistema de monitorización?

Dinámica de Cierre

Seleccionen **una pregunta** y preparen una respuesta conjunta de 30 segundos para compartir con la clase.

Resumen

Consolidando lo aprendido para transformar la teoría en práctica.

Puntos Clave

Ciclo Iterativo y Centrado en Datos

El desarrollo de IA no es lineal. Los datos son ciudadanos de primera clase y su calidad define el techo de rendimiento del modelo, más que el algoritmo en sí.

MLOps es Imperativo, no Opcional

Para escalar más allá de un notebook, necesitas pipelines automatizados (CI/CD/CT), versionado estricto y una infraestructura robusta de monitoreo.

Ética y Gobernanza Continua

La responsabilidad no termina en el despliegue. Detectar sesgos y monitorizar el drift (deriva) es crucial para mantener la confianza y el valor del negocio.

Diseño de Pipeline MLOps

Objetivo: Diseñar un flujo de trabajo robusto y automatizado para un proyecto de Machine Learning.

12 min 4 Roles

Roles del Equipo

Data Engineer
Ingesta, calidad y limpieza

Data Scientist
Entrenamiento y validación

MLOps Engineer
CI/CD, Infra y Despliegue

Negocio / Governance
Compliance y KPIs

MLOps_Pipeline_V1.0

Status: DRAFTING

feature/automation

1. Definir Entradas/Salidas

Data Ops
- Ingesta Datos
- Validación Schema
- Gate: Data Quality

Model Ops
- Preprocesamiento
- Entrenamiento
- Tracking (MLflow)

Evaluación
- Test Set Score
- Check de Sesgos
- Gate: Métrica > Umbral

Despliegue
- Empaquetado (Docker)
- Deploy Staging
- Gate: Aprobación Manual

2. Definir Gates de Calidad

Entregable Esperado

Diagrama del pipeline completando los bloques vacíos. Deben identificar claramente qué pasos son automáticos (CI/CD) y dónde se requiere intervención humana (aprobación).