

Bibliotecas Python para Análisis y Visualización

Unidades 4 y 5 · Programación en Python

Unidad 4

Bibliotecas de Procesamiento Numérico

4.1 · Retos del Análisis de Datos

Volumen y velocidad

Gestionar grandes conjuntos de datos sin agotar memoria.

Calidad de datos

Valores faltantes, duplicados o inconsistentes degradan el análisis.

Heterogeneidad

Distintos formatos: CSV, JSON, bases de datos, APIs externas.

Vectorización

Operar sobre arreglos completos sin ciclos for para máxima eficiencia.


Escalabilidad

Soluciones que funcionen igual para 100 o 10 millones de registros.

Interpretación

Convertir resultados numéricos en decisiones comprensibles.

4.1 · Ciclo del Análisis de Datos



Herramientas clave:

NumPy

Cálculo vectorial y matricial de alta velocidad.

Pandas

Manipulación de tablas, limpieza y agrupamiento.

Matplotlib / Seaborn / Plotly

Gráficas estáticas e interactivas.

4.2 · NumPy — Conceptos Básicos

ndarray

Arreglo N-dimensional: estructura central de NumPy.

shape

Tupla de dimensiones: (filas, columnas) para matrices 2D.

Vectorización

Operaciones sobre todos los elementos sin ciclos for explícitos.

dtype

Tipo de dato homogéneo (int32, float64, bool...).

Broadcasting

Operaciones entre arreglos de distintas formas sin copiar datos.

Indexado

Acceso eficiente a sub-arreglos: `a[1:3, 0:2]`.

4.2 · NumPy — Ejemplos de Código

python

```
import numpy as np
# Operaciones vectorizadas (sin ciclo for)
a = np.array([1, 2, 3, 4, 5])
b = np.array([10, 20, 30, 40, 50])
suma = a + b      # [11, 22, 33, 44, 55]
raiz = np.sqrt(a)  # [1.0, 1.41, 1.73 ...]
```

python

```
# Matriz – calificaciones (alumnos x materias)
cal = np.array([[85,90,78],[92,88,95],[70,75,80]])
cal.shape          # (3, 3)
cal.mean()         # 83.67
cal.mean(axis=1)   # promedio por alumno
cal.max(axis=0)    # máximo por materia
```

python

```
# Álgebra lineal y señales
x = np.linspace(0, 2*np.pi, 100)
y = np.sin(x)
A = np.array([[1,2],[3,4]])
B = np.array([[5,6],[7,8]])
np.dot(A, B)      # producto matricial
```

La vectorización de NumPy es hasta 100× más rápida que los ciclos for de Python equivalentes.

Series (1D)

Índice	Valor
0	Ana
1	Luis
2	María

DataFrame (2D)

Nombre	Edad	Prom.
Ana	20	9.2
Luis	22	8.5

Index	Etiquetas de filas para acceso eficiente y alineación.
.head()	Muestra las primeras 5 filas del DataFrame.
.info()	Tipos de datos y conteo de valores no nulos.
.describe()	Estadísticas descriptivas automáticas.
groupby()	Agrupa filas por categoría para calcular métricas.
apply()	Aplica función personalizada a columnas o filas.
NaN / fillna	Valor faltante y método para reemplazarlo.

4.2 · Pandas — Filtrado, Limpieza y GroupBy

python

```
import pandas as pd, numpy as np
# Filtrado y columna calculada
df = pd.DataFrame({'producto': ['Laptop', 'Mouse', 'Monitor'],
                   'precio': [15000, 350, 6000], 'stock': [10, 50, 8]})
caros = df[df['precio'] > 1000]
df['valor_total'] = df['precio'] * df['stock']
```

python

```
# Manejo de valores faltantes
df['temp'] = df['temp'].fillna(df['temp'].mean())
df.isnull().sum()      # conteo por columna

# GroupBy: ventas por región
ventas.groupby('region')['ventas'].agg(['sum', 'mean', 'max'])
```

Los DataFrames de Pandas transforman datos crudos en conocimiento accionable en pocas líneas.

Unidad 5

Bibliotecas de Visualización de Datos

5.1 · Retos de la Visualización de Datos

Tipo de gráfica

Elegir la gráfica correcta para el tipo de relación a mostrar.

Claridad

Evitar gráficas sobrecargadas, ambiguas o visualmente engañosas.

Escala

Visualizar miles o millones de puntos sin degradar el rendimiento.

Interactividad

Zoom, hover y filtros para exploración dinámica de los datos.

Accesibilidad

Paletas válidas para distintas audiencias y tipos de visión.

Narrativa

Cada gráfica debe contar una historia clara en su contexto.

Guía rápida de selección:

Tipo	Uso	Ejemplo
Barras / Columnas	Comparar categorías	Ventas por región
Líneas	Tendencias en el tiempo	Temperatura mensual
Scatter	Correlación entre 2 variables	Horas estudio vs calificación
Histograma	Distribución de frecuencias	Edades de usuarios

5.2.1 · Matplotlib — Visualización Fundamental

Figure

Contenedor raíz. `plt.figure(figsize=(10,5))``

`plt.plot()`

Dibuja líneas y marcadores conectando puntos (x, y).

`plt.scatter()`

Nube de puntos para mostrar correlación entre variables.

`plt.savefig()`

Guarda la figura: PNG, PDF, SVG, etc.

Axes

Área de dibujo. Una Figure puede tener varios Axes.

`plt.bar()`

Gráfica de barras verticales por categoría.

`plt.show()`

Renderiza y muestra la figura en pantalla.

`subplots()`

Cuadrícula de múltiples gráficas en una sola Figure.

5.2.1 · Matplotlib — Ejemplos

python

```
import matplotlib.pyplot as plt
# Gráfica de líneas - temperatura mensual
meses = ['Ene', 'Feb', 'Mar', 'Abr', 'May', 'Jun',
         'Jul', 'Ago', 'Sep', 'Oct', 'Nov', 'Dic']
temp = [12, 14, 17, 20, 24, 27, 29, 28, 25, 21, 16, 13]
plt.figure(figsize=(10, 5))
plt.plot(meses, temp, marker='o', color='tomato', linewidth=2)
plt.title('Temperatura Promedio Mensual - Toluca')
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout(); plt.show()
```

python

```
# Barras agrupadas - Q1 vs Q2 por departamento
import numpy as np
depts = ['Sistemas', 'Ventas', 'RRHH', 'Finanzas']
q1 = [45000, 72000, 18000, 31000]
q2 = [52000, 68000, 21000, 35000]
x = np.arange(len(depts))
fig, ax = plt.subplots(figsize=(10, 5))
ax.bar(x - 0.175, q1, 0.35, label='Q1', color='steelblue')
ax.bar(x + 0.175, q2, 0.35, label='Q2', color='coral')
ax.set_xticks(x); ax.set_xticklabels(depts); ax.legend()
```

5.2.2 · Seaborn — Visualización Estadística

hue

Colorea por categoría dentro de la misma gráfica.

palette

Conjunto de colores predefinidos (Set1, viridis, coolwarm...).

kde=True

Agrega curva de densidad al histograma.

heatmap()

Mapa de calor: ideal para matrices de correlación.

python

```
import seaborn as sns, pandas as pd, numpy as np
# Heatmap de correlación – sensores IoT
datos = pd.DataFrame({
    'Temp': np.random.normal(25, 3, 100),
    'Hum' : np.random.normal(60, 8, 100),
    'CO2' : np.random.normal(400, 50, 100)})
sns.heatmap(datos.corr(), annot=True,
             fmt='.2f', cmap='coolwarm')

# Scatter con categorías (turno)
sns.scatterplot(data=df, x='horas', y='cal',
                hue='turno', palette='Set1', s=80)
```

Seaborn genera gráficas estadísticas profesionales con menos código que Matplotlib puro.

5.2.3 · Plotly — Visualización Interactiva

Zoom & Pan

El usuario navega la gráfica directamente en el navegador.

Hover info

Tooltip automático al pasar el cursor sobre cada punto.

Dashboards

Integración con Dash para apps web de análisis de datos.

python

```
import plotly.graph_objects as go

meses = ['Ene', 'Feb', 'Mar', 'Abr', 'May', 'Jun',
        'Jul', 'Ago', 'Sep', 'Oct', 'Nov', 'Dic']
v2023 = [42, 55, 60, 48, 72, 85, 90, 78, 65, 70, 80, 95]
v2024 = [50, 62, 71, 55, 80, 88, 95, 83, 70, 75, 88, 102]

fig = go.Figure()
fig.add_trace(go.Scatter(x=meses, y=v2023,
                        mode='lines+markers', name='2023',
                        line=dict(color='royalblue', width=2)))
fig.add_trace(go.Scatter(x=meses, y=v2024,
                        mode='lines+markers', name='2024',
                        line=dict(color='tomato', width=2)))
fig.update_layout(title='Ventas – Comparativo Anual',
                  hovermode='x unified')
fig.show()
```

Comparativo: ¿Qué biblioteca usar?

Biblioteca	Fortaleza	Salida	Cuándo usarla
NumPy	Cómputo numérico vectorizado	Arreglos / matrices	Álgebra lineal, simulaciones
Pandas	Manipulación de datos tabulares	DataFrame / Series	Limpieza, filtrado, EDA
Matplotlib	Control total de la figura	Gráfica estática PNG/PDF	Publicaciones, informes técnicos
Seaborn	Gráficas estadísticas elegantes	Gráfica estática (sobre Mpl)	EDA rápido, histogramas, heatmaps
Plotly	Interactividad web	HTML interactivo / Dash	Dashboards, exploración dinámica

Resumen de la sesión

U4

NumPy

Arreglos N-dimensionales, vectorización y álgebra lineal.

U4

Pandas

DataFrames, limpieza de datos, filtrado, agrupamiento.

U5

Matplotlib

Gráficas base con control total: líneas, barras, subplots.

U5

Seaborn

Histogramas, heatmaps y scatter con paletas estadísticas.

U5

Plotly

Gráficas interactivas para dashboards y exploración dinámica.

```
pip install numpy pandas matplotlib seaborn plotly
```